



INSTITUTO FEDERAL DE EDUCAÇÃO, CIÊNCIA E TECNOLOGIA DO CEARÁ
IFCE *CAMPUS* FORTALEZA

OSVALDO SOARES LANDIM JUNIOR

RELATÓRIO DO CLASSIFICADOR BAYESIANO GAUSSIANO MULTIVARIADO.

FORTALEZA - CE

1 INTRODUÇÃO

Thomas Bayes formulou sua teoria probabilística apenas para o caso de uma distribuição a priori uniforme. Foi Pierre-Simon Laplace quem, independentemente, redescobriu a teoria em sua forma geral e demonstrou sua ampla aplicabilidade (THEODORIDIS; KOUTROUMBAS, 2009). Um problema particularmente importante dizia respeito à chamada probabilidade inversa, cuja solução foi proposta por Bayes em seu artigo "*Ensaio para a Resolução de um Problema na Doutrina das Probabilidades*", publicado postumamente em 1763 (SILVA, 2025).

Assim partindo desses fundamentos, desenvolveu-se o campo do Reconhecimento de Padrões e da Teoria de Decisão de Bayes. Nessa teoria, existe uma abordagem estatística que quantifica o compromisso entre diversas decisões utilizando probabilidades e custos associados (MORAIS; NETO, 2006). Desse modo quando as probabilidades não são completamente conhecidas, estas podem ser estimadas a partir de dados experimentais disponíveis, ou seja, dos vetores de características correspondentes aos padrões do conjunto de treinamento (DUDA; HART; STORK, 2001).

Nesse contexto, o problema de classificação pode ser formalmente definido a partir de um conjunto de amostras rotuladas: dada uma tupla $Z = (X, Y)$ tal que $X = \{\vec{x}_1, \vec{x}_2, \dots, \vec{x}_n\}$ é um conjunto de amostras (ou vetores), com $\vec{x}_i \in \mathbb{R}^d$, e $Y = \{y_1, y_2, \dots, y_n\}$ é um conjunto de rótulos, em que $y_i \in \{1, 2, \dots, c\}$, um **classificador** é uma função $f : X \rightarrow Y$ que prediz um $y \in Y$ para todo $\vec{x} \in X$. A função $f : X \rightarrow Y$ induz uma partição em X em classes ou regiões de decisão (LEVADA, 2025). Diante disso há diversas estratégias que foram propostas na literatura para construir tal função de classificação, principalmente nas hipóteses assumidas sobre a distribuição dos dados e na forma como a fronteira de decisão é determinada (BISHOP, 2006).

Dentre os classificadores existentes na literatura, três se destacam pela sua simplicidade e eficácia. O **Classificador Bayesiano Multivariado** baseia-se na regra de decisão de Bayes, assumindo que os dados seguem uma distribuição Gaussiana multivariada em cada classe, estimando os parâmetros necessários — vetor de médias $\vec{\mu}_i$ e matriz de covariância Σ_i — diretamente a partir dos dados de treinamento (DUDA; HART; STORK, 2001; BISHOP, 2006). O **Classificador de Distância Mínima** (DMC) atribui cada padrão à classe cujo centroide é o mais próximo no espaço de características, sendo uma abordagem geométrica e computacionalmente eficiente (THEODORIDIS; KOUTROUMBAS, 2009). Já o **K-Vizinhos Mais Próximos** (KNN) é um método não paramétrico que classifica um novo padrão com base na classe majoritária entre os K exemplos de treinamento mais próximos, sem assumir qualquer forma para a distribuição

dos dados (KANG; NETO, 2025).

Assim a escolha entre esses classificadores envolve um compromisso entre diferentes hipóteses sobre os dados. O Bayesiano Multivariado é ótimo quando a suposição gaussiana é válida (BISHOP, 2006), o DMC é eficaz quando as classes são bem separadas e compactas, e o KNN é flexível mas sensível à dimensionalidade e ao valor de K (LEVADA, 2025). Comparar esses métodos em diferentes conjuntos de dados permite avaliar como cada um se comporta diante de distribuições distintas e graus variados de complexidade (DOUGHERTY, 2013).

Portanto este relatório propõe comparar os classificadores Bayesiano Multivariado, KNN e DMC aplicados a cinco conjuntos de dados: Flor Íris, Coluna Vertebral, Breast Cancer, Dermatology e Artificial, avaliando o desempenho de cada método por meio de métricas de acurácia e análise dos resultados obtidos.

2 METODOLOGIA

Nesta seção as quantidades estatísticas fundamentais para a classificação bayesiana são as **funções de densidade de probabilidade condicionais às classes** $p(\vec{x}|\omega_i)$, $i = 1, 2, \dots, c$, que assim descrevem a distribuição dos vetores de características em cada uma dessas classes. Com isso a função $p(\vec{x}|\omega_i)$ é frequentemente denominada pela *função de verossimilhança* de ω_i em relação a $\vec{x}$. Portanto, quando a priori não são conhecidas, essas funções podem ser estimadas a partir dos dados de treinamento disponíveis (BISHOP, 2006).

Em suma assumindo que as probabilidades a priori $P(\omega_i)$ e as funções de verossimilhança $p(\vec{x}|\omega_i)$ são conhecidas, a **regra de Bayes** permite calcular as probabilidades a posteriori:

$$P(\omega_i|\vec{x}) = \frac{p(\vec{x}|\omega_i)P(\omega_i)}{p(\vec{x})} \quad (2.1)$$

Alem disso a regra de classificação de Bayes consiste em atribuir o padrão $\vec{x}$ à classe ω_i que maximiza a probabilidade a posteriori $P(\omega_i|\vec{x})$, ou equivalentemente, assim maximizando o produto $p(\vec{x}|\omega_i)P(\omega_i)$, uma vez que $p(\vec{x})$ é constante para todas as classes e não influenciara na decisão. Contudo no caso em que as probabilidades a priori são iguais, isto é, $P(\omega_1) = P(\omega_2) = \dots = P(\omega_c) = \frac{1}{c}$, a regra se reduz à maximização direta da verossimilhança $p(\vec{x}|\omega_i)$ (THEODORIDIS; KOUTROUMBAS, 2009).

Logo para modelar a distribuição de cada classe ω_i , assume-se que os dados seguem uma distribuição Gaussiana multivariada, cuja função densidade de probabilidade contínua é dada por c:

$$p(\vec{x}) = \frac{1}{(2\pi)^{d/2}|\Sigma|^{1/2}} \cdot \exp \left\{ -\frac{1}{2}(\vec{x} - \vec{\mu})^T \Sigma^{-1}(\vec{x} - \vec{\mu}) \right\} \quad (2.2)$$

onde $\vec{x}$ é um vetor da coluna com d componentes, $\vec{\mu}$ é um vetor das médias também com d componentes e Σ é a matriz de covariância de tamanho $d \times d$. Dessa forma os termos $|\Sigma|$ e Σ^{-1} representam o determinante e a inversa da matriz de covariância, respectivamente na formula.

Portanto a matriz de covariância Σ desempenha um papel importante e central na modelagem da distribuição do conjunto de dados, pois assim captura tanto as variâncias individuais de cada característica quanto as correlações entre pares das características. Formalmente, seus elementos são definidos como:

$$\Sigma_{ij} = \mathbb{E}[(x_i - \mu_i)(x_j - \mu_j)] \quad (2.3)$$

onde o Σ_{ij} representa a covariância entre os componentes i e j do vetor $\vec{x}$. Do mesmo modo quando é $i = j$, obtém a variância da i -ésima característica, e quando $i \neq j$, obtém-se a correlação entre as características i e j . Em síntese a matriz Σ é sempre simétrica (THEODORIDIS; KOUTROUMBAS, 2009).

O termo $(\vec{x} - \vec{\mu})^T \Sigma^{-1} (\vec{x} - \vec{\mu})$ é denominado por *distância de Mahalanobis* ao quadrado entre o padrão $\vec{x}$ e o centroide $\vec{\mu}$ da classe, e generaliza a distância Euclidiana ao levar em conta a correlação entre as variáveis (DUDA; HART; STORK, 2001). Essa distância é o que torna o classificador bayesiano multivariado capaz de modelar fronteiras de decisão.

Os parâmetros $\vec{\mu}_i$ e Σ_i de cada classe ω_i são estimados diretamente a partir dos dados de treinamento via Máxima Verossimilhança (MLE), resultando nos estimadores (DUDA; HART; STORK, 2001):

$$\hat{\vec{\mu}}_i = \frac{1}{n_i} \sum_{k=1}^{n_i} \vec{x}_k \quad (2.4)$$

$$\hat{\Sigma}_i = \frac{1}{n_i} \sum_{k=1}^{n_i} (\vec{x}_k - \hat{\vec{\mu}}_i)(\vec{x}_k - \hat{\vec{\mu}}_i)^T \quad (2.5)$$

onde n_i é o número de amostras pertencentes à classe ω_i . Com esses parâmetros estimados, a verossimilhança $p(\vec{x}|\omega_i)$ pode ser calculada para qualquer novo padrão $\vec{x}$, permitindo aplicar a regra de classificação de Bayes.

2.1 Classificadores de Referência

Para avaliar o desempenho do classificador bayesiano gaussiano, dois classificadores adicionais são utilizados como referência: o classificador por *K Vizinhos Mais Próximos* (KNN) e o classificador de *Distância Mínima ao Centróide* (DMC).

2.1.1 K Vizinhos Mais Próximos (KNN)

O classificador KNN é um método não-paramétrico que atribui o rótulo de um padrão de teste $\vec{x}$ com base nos rótulos dos k padrões de treinamento mais próximos, segundo a distância

Euclidiana (DUDA; HART; STORK, 2001):

$$d(\vec{x}, \vec{x}_j) = \|\vec{x} - \vec{x}_j\|_2 = \sqrt{\sum_{l=1}^d (x_l - x_{jl})^2} \quad (2.6)$$

A classe predita é determinada pela regra de voto majoritário entre os k vizinhos selecionados:

$$\hat{\omega}(\vec{x}) = \omega_i \sum_{j \in \mathcal{N}_k(\vec{x})} \mathbf{1}[y_j = \omega_i] \quad (2.7)$$

onde $\mathcal{N}_k(\vec{x})$ denota o conjunto dos índices dos k vizinhos mais próximos de $\vec{x}$ no conjunto de treinamento. Nos experimentos com os *datasets* Breast Cancer Wisconsin, Dermatology e Coluna Vertebral foi utilizado $k = 5$; no *dataset* Iris foi utilizado $k = 3$; e no *dataset* Artificial I foi utilizado $k = 5$.

2.1.2 Classificador de Distância Mínima ao Centróide (DMC)

O classificador DMC é um método paramétrico simples que representa cada classe ω_i pelo centróide $\vec{c}_i$, calculado como a média aritmética de todas as amostras de treinamento pertencentes a essa classe:

$$\vec{c}_i = \frac{1}{n_i} \sum_{k=1}^{n_i} \vec{x}_k^{(i)} \quad (2.8)$$

A classificação de um novo padrão $\vec{x}$ é feita atribuindo-o à classe cujo centróide está mais próximo em distância Euclidiana:

$$\hat{\omega}(\vec{x}) = \omega_i \|\vec{x} - \vec{c}_i\|_2 \quad (2.9)$$

O DMC é equivalente ao classificador bayesiano gaussiano sob a hipótese de que todas as classes compartilham a mesma matriz de covariância $\Sigma_i = \sigma^2 \mathbf{I}$ e possuem a mesma probabilidade a priori $P(\omega_i)$, sendo portanto um caso particular e mais restritivo do classificador bayesiano.

2.2 Conjuntos de Dados

Os três classificadores foram avaliados em cinco conjuntos de dados: um sintético e quatro provenientes de repositórios públicos de aprendizado de máquina. A Tabela 1 apresenta um resumo das características de cada *dataset*.

Tabela 1 – Resumo dos conjuntos de dados utilizados nos experimentos.

Dataset	Amostras	Features	Classes	Divisão
Artificial I	120	2	3	80/20
Iris	150	4	3	80/20
Breast Cancer (WDBC)	569	30	2	80/20
Dermatology	366	35	6	80/20
Coluna Vertebral (2C)	310	6	2	80/20
Coluna Vertebral (3C)	310	6	3	80/20

2.2.1 Dataset Artificial I

O *Dataset Artificial I* foi gerado sinteticamente com o objetivo de fornecer um cenário controlado onde as suposições do classificador bayesiano gaussiano são exatamente satisfeitas. O conjunto é composto por três classes bidimensionais, cada uma com 40 amostras (total de 120 padrões), geradas a partir de distribuições gaussianas multivariadas com os seguintes parâmetros:

- **Classe 0 — Círculos:** $\vec{\mu}_0 = [1,5 \ 7,0]^T$, $\Sigma_0 = 0,4\mathbf{I}$;
- **Classe 1 — Triângulos:** $\vec{\mu}_1 = [6,5 \ 7,0]^T$, $\Sigma_1 = \begin{bmatrix} 0,50 & 0,10 \\ 0,10 & 0,30 \end{bmatrix}$;
- **Classe 2 — Estrelas:** $\vec{\mu}_2 = [4,0 \ 3,5]^T$, $\Sigma_2 = 0,4\mathbf{I}$.

Por ser um problema bidimensional, a superfície de decisão pode ser visualizada diretamente no espaço original das características, permitindo inspecionar as fronteiras elípticas produzidas pelo classificador bayesiano e compará-las com as fronteiras lineares do DMC. A divisão treino/teste foi de 80%/20% sem estratificação, com 20 sementes distintas para garantir a independência entre realizações.

2.2.2 Iris

O *Dataset Iris* (FISHER, 1988) é um dos conjuntos de dados mais utilizados na literatura de reconhecimento de padrões. Contém 150 amostras de flores da espécie *Iris*, distribuídas igual-

mente entre três classes *Iris setosa*, *Iris versicolor* e *Iris virginica* (50 amostras cada) descritas por quatro características morfológicas: comprimento e largura das sépalas, e comprimento e largura das pétalas, todas em centímetros.

O *dataset* não apresenta valores ausentes. A divisão treino/teste foi de 80%/20% com estratificação por classe, assegurando que a proporção de amostras de cada classe seja preservada em ambos os subconjuntos. O parâmetro $k = 3$ foi adotado para o KNN nesse experimento.

2.2.3 *Breast Cancer Wisconsin (WDBC)*

O *Dataset Breast Cancer Wisconsin Diagnostic* (WDBC) (WOLBERG *et al.*, 1995) é amplamente utilizado para tarefas de classificação binária em diagnóstico médico. Contém 569 amostras de biópsias de tumor de mama, classificadas em duas classes: Benigno (357 amostras) e Maligno (212 amostras). Para cada amostra, são fornecidas 30 características numéricas derivadas de imagens digitalizadas de aspirados com agulha fina (*fine needle aspirate* — FNA), incluindo raio, textura, perímetro, área, suavidade, compacidade, concavidade, simetria e dimensão fractal dos núcleos celulares, cada uma representada pela média, erro padrão e pior valor.

Devido à grande diferença de escala entre as features, os dados foram pré-processados com normalização *z-score* (média zero e variância unitária). A divisão treino/teste foi de 80%/20% com estratificação.

2.2.4 *Dermatology*

O *Dataset Dermatology* (ILTER; GUVENIR, 1997) é um conjunto de dados clínicos para diagnóstico diferencial de doenças eritematoso-escamosas da pele. Contém 366 amostras distribuídas em seis classes:

1. Psoríase (*Psoriasis*);
2. Dermatite Seborréica (*Seboric Dermatitis*);
3. Líquen Plano (*Lichen Planus*);
4. Pitiríase Rósea (*Pityriasis Rosea*);
5. Dermatite Crônica (*Chronic Dermatitis*);
6. Pitiríase Rubra Pilar (*Pityriasis Rubra Pilaris*).

Cada amostra é descrita por 34 características clínicas e histopatológicas (variáveis ordinais no intervalo $[0, 3]$, com exceção da característica *família*, que é binária) acrescidas da idade do paciente, totalizando 35 atributos. A única coluna com valores ausentes é a idade, cujos valores faltantes foram substituídos pela mediana da coluna calculada sobre o conjunto de treinamento. A divisão treino/teste foi de 80%/20% com estratificação por classe.

2.2.5 Coluna Vertebral

O *Dataset Vertebral Column* (BARRETO; NETO, 2011) contém medidas biomecânicas da coluna vertebral de 310 pacientes, descritos por seis atributos numéricos:

- Incidência pélvica (*pelvic incidence*);
- Inclinação pélvica (*pelvic tilt*);
- Ângulo de lordose lombar (*lumbar lordosis angle*);
- Inclinação sacral (*sacral slope*);
- Raio pélvico (*pelvic radius*);
- Grau de espondilolistese (*degree of spondylolisthesis*).

O *dataset* é disponibilizado em dois formatos de classificação:

- **2 Classes (2C):** Normal (100 amostras) vs. Anormal (210 amostras);
- **3 Classes (3C):** Normal (100), Hérnia de Disco (60) e Espondilolistese (150).

Ambas as configurações foram avaliadas separadamente. Os dados foram lidos diretamente no formato ARFF. A divisão treino/teste foi de 80%/20% com estratificação por classe e $k = 5$ para o KNN.

2.3 Desenvolvimento

Para cada conjunto de dados, os três classificadores foram avaliados por meio de **20 realizações independentes** com partições treino/teste geradas por diferentes sementes aleatórias (de 0 a 19). Em cada realização, os passos seguidos foram:

Particionamento estratificado: o conjunto de dados é dividido de forma estratificada, preservando a proporção de amostras de cada classe nos subconjuntos de treino e teste. O Dataset Artificial I e o Vertebral Column utilizaram divisão 80%/20%; os demais utilizaram 80%/20%.

Pré-processamento: quando aplicável (Breast Cancer WDBC), a normalização *z-score* é estimada exclusivamente com as amostras de treinamento e aplicada tanto ao treino quanto ao teste, evitando *data leakage*. Para o *dataset* Dermatology, os valores ausentes de idade são substituídos pela mediana do treinamento.

Ao final das 20 realizações, são reportadas a **acurácia média** $\bar{a}$ e o **desvio padrão** s de cada classificador:

$$\bar{a} = \frac{1}{20} \sum_{r=1}^{20} a_r, \quad s = \sqrt{\frac{1}{20} \sum_{r=1}^{20} (a_r - \bar{a})^2} \quad (2.10)$$

Para a análise qualitativa, é selecionada a realização cuja acurácia do GBC é mais próxima da mediana das 20 realizações. Sobre essa realização representativa são geradas a **matriz de confusão** e a **visualização das gaussianas** por classe. Nos *datasets* com mais de duas dimensões, a visualização é feita mediante projeção dos dados nos dois primeiros componentes principais (PCA), sobre os quais são desenhadas as elipses de covariância de 1σ e 2σ de cada classe. A comparação global entre os três classificadores é apresentada em gráficos de caixa das 20 acurácias.

3 RESULTADOS E CONCLUSÃO

3.1 Resultados

A Tabela 2 apresenta a acurácia média e o desvio padrão obtidos pelos três classificadores Gaussiano Bayesiano (GBC), K Vizinhos Mais Próximos (KNN) e Distância Mínima ao Centróide (DMC) nas 20 realizações de cada conjunto de dados.

Tabela 2 – Acurácia média $\pm$ desvio padrão (%) nas 20 realizações. O melhor resultado em cada linha está em **negrito**.

Dataset	Divisão	GBC	KNN	DMC
Artificial I	80/20	99,58 $\pm$ 0,99	99,58 $\pm$ 0,99	99,86 $\pm$ 0,61
Iris	80/20	96,50 $\pm$ 3,07	95,67 $\pm$ 3,18	90,83 $\pm$ 3,78
Breast Cancer (WDBC)	80/20	94,91 $\pm$ 1,79	96,27 $\pm$ 1,52	92,68 $\pm$ 1,45
Dermatology	80/20	89,66 $\pm$ 2,81	86,55 $\pm$ 3,93	53,72 $\pm$ 5,02
Coluna Vertebral (2C)	80/20	80,97 $\pm$ 4,69	83,31 $\pm$ 3,36	74,76 $\pm$ 5,13
Coluna Vertebral (3C)	80/20	83,23 $\pm$ 3,93	82,42 $\pm$ 4,44	75,56 $\pm$ 5,38

3.2 Análise dos Resultados

3.2.1 Dataset Artificial I




Figura 1 – Superfície de decisão do classificador Bayes Gaussiano — Dataset Artificial I

No *Dataset Artificial I*, os três classificadores apresentaram desempenho quase perfeito, com acurácias superiores a 99%, conforme ilustrado pela matriz de confusão da Figura 2. O DMC obteve acurácia ligeiramente superior (99,86%) ao GBC e ao KNN (99,58% cada),




Figura 2 – Matrizes de confusão dos três classificadores — Dataset Artificial I

com menor desvio padrão. Esse resultado era esperado, uma vez que o dataset foi gerado a partir de gaussianas com matrizes de covariância próximas a múltiplos da identidade e bem separadas no espaço 2D, satisfazendo as hipóteses simplificadoras do DMC (classes esféricas e equiprováveis). Nesse cenário ideal, a complexidade adicional do GBC não traz ganho, mas também não prejudica.

3.2.2 Iris




Figura 3 – Distribuições gaussianas por classe — Iris (atributos *petal length* × *petal width*)




Figura 4 – Matrizes de confusão dos três classificadores — Iris

No *dataset* Iris, o GBC alcançou a maior acurácia média ($96,50\% \pm 3,07\%$), seguido pelo KNN ($k=3$) com $95,67\% \pm 3,18\%$ e pelo DMC ($90,83\% \pm 3,78\%$). A diferença entre GBC e DMC é de aproximadamente 5,67 pontos percentuais, evidenciando que as classes Iris não são esféricas no espaço de características e que o uso de matrizes de covariância independentes por classe contribui significativamente para a qualidade da fronteira de decisão.

3.2.3 Breast Cancer Wisconsin (WDBC)




Figura 5 – Distribuições gaussianas por classe no espaço PCA 2D — Breast Cancer Wisconsin




Figura 6 – Matrizes de confusão dos três classificadores — Breast Cancer Wisconsin

No *dataset* WDBC, com 30 features e apenas duas classes, o KNN ($k=5$) obteve o melhor desempenho médio ($96,27\% \pm 1,52\%$), seguido pelo GBC ($94,91\% \pm 1,79\%$) e pelo DMC ($92,68\% \pm 1,45\%$). O GBC, por sua vez, supera o DMC em $\approx 2,2$ pontos percentuais, confirmando que a heterogeneidade das covariâncias entre as classes Benigno e Maligno é relevante para o problema.

3.2.4 Dermatology

O *dataset* Dermatology é onde as diferenças entre os classificadores são mais expressivas. O GBC obteve acurácia média de $89,66\% \pm 2,81\%$, o KNN ($k=5$) de $86,55\% \pm 3,93\%$ e o DMC de apenas $53,72\% \pm 5,02\%$ próximo de uma classificação aleatória para seis classes equiprováveis ($\approx 16,7\%$ esperado). Esse colapso do DMC reflete a inadequação do modelo de fronteiras lineares para separar seis classes clínicas com distribuições altamente sobrepostas




Figura 7 – Distribuições gaussianas por classe (projecção PCA 2D) — Dermatology




Figura 8 – Matrizes de confusão dos três classificadores — Dermatology

e covariâncias heterogêneas. O GBC demonstrou robustez superior nesse cenário de alta complexidade, superando o KNN em $\approx 3,1$ pontos percentuais.

3.2.5 Coluna Vertebral




Figura 9 – Distribuição gaussiana (PCA 2D) e matriz de confusão GBC — Coluna Vertebral (2 Classes)

Na configuração binária (2C), o KNN ($k=5$) superou o GBC marginalmente ($83,31\% \pm 3,4\%$ vs. $80,97\% \pm 4,7\%$), enquanto na configuração ternária (3C) o GBC se sobressaiu ($83,23\% \pm 3,9\%$ vs. $82,42\% \pm 4,4\%$). Em ambas as configurações o DMC ficou $\approx 6-8$ pontos




Figura 10 – Distribuição gaussiana (PCA 2D) e matriz de confusão GBC — Coluna Vertebral (3 Classes)

abaixo dos demais (74,8% em 2C e 75,6% em 3C), indicando que as classes biomecânicas não são bem separadas por hiperplanos lineares. O GBC apresentou maior desvio padrão que o KNN no problema 2C (4,7% vs. 3,4%), sugerindo maior sensibilidade à variação da partição treino/teste quando a quantidade de amostras por classe é reduzida.

3.3 Conclusão

Este trabalho avaliou três classificadores GBC, KNN e DMC em cinco conjuntos de dados de complexidade crescente, por meio de 20 realizações independentes. Os principais achados são:

O classificador Bayesiano Gaussiano é robusto e competitivo. Em quatro dos seis cenários avaliados, o GBC obteve desempenho igual ou superior ao KNN, demonstrando que a modelagem explícita da distribuição de cada classe via gaussiana multivariada é uma estratégia eficaz, especialmente em problemas multiclasse com covariâncias heterogêneas (Iris, Dermatology, Coluna 3C).

O DMC é insuficiente para dados com covariâncias heterogêneas. O colapso do DMC no *dataset* Dermatology (53,72%) e seu desempenho inferior em todos os datasets reais evidenciam que a hipótese de fronteiras lineares não se sustenta em problemas de classificação com distribuições assimétricas e sobrepostas. O DMC deve ser reservado a situações em que as classes são compactas, esféricas e bem separadas.

O KNN é competitivo em espaços de alta dimensão. O KNN superou o GBC no WDBC (30 features) e na Coluna Vertebral 2C, onde a fronteira de decisão baiana pode ser prejudicada por estimativas ruidosas de covariância com poucos dados por classe.

Dados sintéticos favorecem o DMC. No Dataset Artificial I, gerado com covariâncias esféricas bem condicionadas, o DMC alcançou o melhor desempenho (99,86%), confirmando que as suposições simplificadoras do modelo linear são satisfeitas nesse caso particular.

Em síntese, o classificador bayesiano gaussiano multivariado se mostrou uma escolha sólida e interpretável para problemas de classificação supervisionada, com desempenho superior ao DMC em todos os datasets reais e comparáveis ou superior ao KNN na maioria dos cenários avaliados.

REFERÊNCIAS

- BARRETO, G.; NETO, A. R. **Vertebral Column**. UCI Machine Learning Repository, 2011. Disponível em: <<https://doi.org/10.24432/C5K89B>>.
- BISHOP, C. M. **Pattern Recognition and Machine Learning**. [S.l.]: Springer, 2006.
- DOUGHERTY, G. **Pattern Recognition and Classification: An Introduction**. New York, NY, USA: Springer, 2013. ISBN 978-1-4614-5322-2.
- DUDA, R. O.; HART, P. E.; STORK, D. G. **Pattern Classification**. 2. ed. [S.l.]: Wiley-Interscience, 2001.
- FISHER, R. **Íris**. UCI Machine Learning Repository, 1988. Dataset com 310 instâncias e 6 atributos biomecânicos para classificação de patologias ortopédicas em 3 classes (normal, hérnia de disco, espondilolistese) ou 2 classes (normal ou anormal). Doador em 08/08/2011. Disponível em: <<https://doi.org/10.24432/C5K89B>>.
- ILTER, N.; GUVENIR, H. **Dermatology**. UCI Machine Learning Repository, 1997. Disponível em: <<https://doi.org/10.24432/C56C76>>.
- KANG, M.; NETO, J. F. S. R. Attention via convolutional nearest neighbors. Brunswick, ME, USA, 2025. Disponível em: <<https://arxiv.org/abs/2511.14137>>.
- LEVADA, A. L. M. **Classificação Supervisionada de Padrões: Apostila sobre Fundamentos de Aprendizado de Máquina para Classificação**. São Carlos, SP, Brasil, 2025. Versão de 13 de outubro de 2025.
- MORAIS, C. R. d.; NETO, A. R. d. R. **Diagnóstico de Patologias da Coluna Vertebral via Janela de Parzen**. Maracanaú, CE, Brasil, 2006. Pró-Reitoria de Pesquisa e Inovação (PRPI). Bolsista: Camila Rodrigues de Moraes. Orientador: Ajalmar Rêgo da Rocha Neto.
- SILVA, S. L. **O Teorema de Bayes: Aplicações e Abordagens Didáticas no Ensino e na Tomada de Decisão**. Monografia (Trabalho de Conclusão de Curso) — Instituto Federal da Paraíba, Campina Grande, PB, Brasil, março 2025. Curso de Licenciatura em Matemática. Orientador: Prof. Me. Baldoíno Sonido da Nóbrega. Examinador Interno: Prof. Dr. Jonathas Jerônimo Barbosa. Examinador Externo: Prof. Me. Alex Pereira Bezerra (UFRPE).
- THEODORIDIS, S.; KOUTROUMBAS, K. **Pattern Recognition**. 4. ed. Burlington, MA, USA: Academic Press, 2009. ISBN 978-1-59749-272-0.
- WOLBERG, W.; MANGASARIAN, O.; STREET, N.; STREET, W. **Breast Cancer Wisconsin (Diagnostic)**. UCI Machine Learning Repository, 1995. Dataset com 569 instâncias e 30 atributos para diagnóstico de câncer de mama em 2 classes: maligno e benigno. Doador em 31/10/1995. Disponível em: <<https://archive.ics.uci.edu/dataset/17/breast+cancer+wisconsin+diagnostic>>.