



INSTITUTO FEDERAL DE EDUCAÇÃO, CIÊNCIA E TECNOLOGIA DO CEARÁ
IFCE *CAMPUS* FORTALEZA

OSVALDO SOARES LANDIM JUNIOR

RELATÓRIO DO CLASSIFICADOR NAIVE BAYES.

FORTALEZA - CE

1 INTRODUÇÃO

A abordagem dos classificadores Naive Bayes utiliza o teorema de Bayes com suspeita ingênua da independência condicional entre as características, dado cada rótulo das classes. O algoritmo calcula probabilisticamente e é computacionalmente eficaz e apresenta um desempenho considerável para diversas tarefas assim assumindo especificamente que as características seguem uma distribuição Gaussiana de classificação (MANGALA *et al.*, 2025). A função de decisão do Naive Bayes Gaussiano pode ser representada como :

$$f(x) = \underset{c}{\operatorname{argmax}} P(C = c) \prod_{i=1}^n P(X_i = x_i | C = c)$$

onde $f(x)$ representa o rótulo de classe previsto para a instância de entrada. Ao aproveitar a natureza probabilística do Naive Bayes Gaussiano podemos capturar efetivamente a probabilidade de uma instância pertencer a uma determinada classe com base em seus valores de características.

Ao aproveitar a natureza probabilística do Naive Bayes Gaussiano, podemos capturar efetivamente a probabilidade de uma instância pertencer a uma determinada classe com base em seus valores de características. A suposição do algoritmo de independência de características permite eficiência e simplicidade computacionais (CANH; HOANGVAN,).

Portanto este relatório propõe comparar os classificadores Naive Bayes, KNN e DMC aplicados a cinco conjuntos de dados: Flor Íris, Coluna Vertebral, Breast Cancer, Dermatology e Artificial, avaliando o desempenho de cada método por meio de métricas de acurácia e análise dos resultados obtidos.

2 METODOLOGIA

2.1 Classificadores

Nesta seção, descrevem-se os três classificadores implementados — *Naive Bayes Gaussiano* (GNB), *K Vizinhos Mais Próximos* (KNN) e *Distância Mínima ao Centróide* (DMC) —, os conjuntos de dados utilizados e o protocolo experimental adotado.

2.1.1 *Naive Bayes Gaussiano* (GNB)

O classificador *Naive Bayes Gaussiano* é fundamentado no teorema de Bayes com a suposição de independência condicional entre as características, dado o rótulo de classe (BISHOP, 2006). Dado um vetor de características $\vec{x} = (x_1, \dots, x_n)$ e um conjunto de classes $\omega_i, i = 1, \dots, c$, a probabilidade a posteriori de cada classe é:

$$P(\omega_i | \vec{x}) = \frac{p(\vec{x} | \omega_i) P(\omega_i)}{p(\vec{x})} \quad (2.1)$$

A hipótese de independência condicional permite fatorar a verossimilhança como produto de densidades univariadas:

$$p(\vec{x} | \omega_i) = \prod_{j=1}^n p(x_j | \omega_i) \quad (2.2)$$

A regra de decisão, no domínio logarítmico para evitar *underflow* numérico, é:

$$f(\vec{x}) = \omega_i \left[\log P(\omega_i) + \sum_{j=1}^n \log p(x_j | \omega_i) \right] \quad (2.3)$$

Para dados contínuos, assume-se que cada atributo x_j segue uma distribuição Gaussiana univariada dada a classe ω_i :

$$p(x_j | \omega_i) = \frac{1}{\sqrt{2\pi \sigma_{ij}^2}} \exp \left\{ -\frac{(x_j - \mu_{ij})^2}{2\sigma_{ij}^2} \right\} \quad (2.4)$$

cujo logaritmo é diretamente computado na implementação como:

$$\log p(x_j | \omega_i) = -\frac{1}{2} \log(2\pi \sigma_{ij}^2) - \frac{(x_j - \mu_{ij})^2}{2\sigma_{ij}^2} \quad (2.5)$$

Os parâmetros μ_{ij} e σ_{ij}^2 são estimados por Máxima Verossimilhança a partir das amostras de treinamento da classe ω_i :

$$\mu_{ij} = \frac{1}{n_i} \sum_{k \in \omega_i} x_{kj}, \quad \sigma_{ij} = \sqrt{\frac{1}{n_i} \sum_{k \in \omega_i} (x_{kj} - \mu_{ij})^2 + \varepsilon} \quad (2.6)$$

onde $\varepsilon = 10^{-9}$ é adicionado ao desvio padrão para estabilidade numérica. As probabilidades a priori são estimadas pela frequência relativa de cada classe no conjunto de treinamento:

$$P(\omega_i) = \frac{n_i}{n} \quad (2.7)$$

2.1.2 *K Vizinhos Mais Próximos (KNN)*

O classificador KNN é um método não-paramétrico que atribui o rótulo de um padrão de teste $\vec{x}$ com base nos rótulos dos k padrões de treinamento mais próximos segundo a distância Euclidiana (DUDA; HART; STORK, 2001):

$$d(\vec{x}, \vec{x}_j) = \|\vec{x} - \vec{x}_j\|_2 = \sqrt{\sum_{l=1}^d (x_l - x_{jl})^2} \quad (2.8)$$

A classe predita é determinada pelo voto majoritário entre os k vizinhos selecionados:

$$\hat{\omega}(\vec{x}) = \sum_{\omega_i \in \mathcal{N}_k(\vec{x})} \mathbf{1}[y_j = \omega_i] \quad (2.9)$$

onde $\mathcal{N}_k(\vec{x})$ denota o conjunto dos índices dos k vizinhos mais próximos de $\vec{x}$ no conjunto de treinamento. Em todos os experimentos foi utilizado $k = 5$.

2.1.3 *Distância Mínima ao Centróide (DMC)*

O classificador DMC representa cada classe ω_i pelo centróide $\vec{c}_i$, calculado como a média aritmética de todas as amostras de treinamento pertencentes a essa classe:

$$\vec{c}_i = \frac{1}{n_i} \sum_{k=1}^{n_i} \vec{x}_k^{(i)} \quad (2.10)$$

A classificação de um novo padrão $\vec{x}$ é feita atribuindo-o à classe cujo centróide está mais próximo em distância Euclidiana:

$$\hat{\omega}(\vec{x}) = \omega_i \|\vec{x} - \vec{c}_i\|_2 \quad (2.11)$$

2.2 Conjuntos de Dados

Os três classificadores foram avaliados em cinco conjuntos de dados: um sintético e quatro provenientes de repositórios públicos. A Tabela 1 apresenta um resumo das características de cada *dataset*.

Tabela 1 – Resumo dos conjuntos de dados utilizados nos experimentos.

Dataset	Amostras	Features	Classes	Divisão
Artificial I	300	2	3	80/20 (estratificado)
Iris	150	4	3	80/20 (estratificado)
Breast Cancer (WDBC)	569	30	2	80/20 (estratificado)
Dermatology	366	34	6	80/20 (estratificado)
Coluna Vertebral (3C)	310	6	3	80/20 (estratificado)

2.2.1 Dataset Artificial I

O *Dataset Artificial I* foi gerado sinteticamente com o objetivo de fornecer um cenário controlado onde as suposições do classificador bayesiano gaussiano são aproximadamente satisfeitas. O conjunto é composto por três classes bidimensionais, cada uma com 100 amostras (total de 300 padrões), geradas a partir de distribuições gaussianas multivariadas com semente fixa (`DATASET_SEED = 42`):

- **Classe 0:** $\vec{\mu}_0 = [-2,0 \ -2,0]^T$, $\Sigma_0 = \begin{bmatrix} 1,0 & 0,3 \\ 0,3 & 1,0 \end{bmatrix}$;
- **Classe 1:** $\vec{\mu}_1 = [\ 2,0 \ -2,0]^T$, $\Sigma_1 = \begin{bmatrix} 1,0 & -0,3 \\ -0,3 & 1,0 \end{bmatrix}$;
- **Classe 2:** $\vec{\mu}_2 = [\ 0,0 \ \ 2,0]^T$, $\Sigma_2 = \begin{bmatrix} 1,0 & 0,0 \\ 0,0 & 1,0 \end{bmatrix}$.

Por ser um problema bidimensional, a superfície de decisão é visualizada diretamente no espaço original das características. A divisão treino/teste foi de 80%/20% **com estratificação** por classe e 20 sementes distintas (0 a 19).

2.2.2 Iris

O *Dataset Iris* (FISHER, 1988) contém 150 amostras distribuídas igualmente entre três classes (*Iris setosa*, *Iris versicolor* e *Iris virginica*), descritas por quatro características morfológicas. A divisão treino/teste foi de 80%/20% com estratificação por classe. A visualização das superfícies de decisão e gaussianas utiliza os atributos *petal length* (índice 2) e *petal width* (índice 3), por serem os mais discriminativos.

2.2.3 Breast Cancer Wisconsin (WDBC)

O *Dataset Breast Cancer Wisconsin Diagnostic* (WDBC) (WOLBERG *et al.*, 1995) contém 569 amostras classificadas em Benigno (B) e Maligno (M), descritas por 30 características numéricas. Devido à grande diferença de escala entre as *features*, os dados foram pré-processados com normalização *z-score* estimada exclusivamente sobre o conjunto de treinamento e aplicada ao treino e ao teste, evitando *data leakage*. A divisão treino/teste foi de 80%/20% com estratificação por classe.

2.2.4 Dermatology

O *Dataset Dermatology* (ILTER; GUVENIR, 1997) contém 366 amostras distribuídas em seis classes de doenças eritematoso-escamosas, descritas por 34 características clínicas e histopatológicas. A coluna de idade (*age*) contém valores ausentes (marcados com ?), que foram substituídos pela **média global** da coluna, calculada sobre o conjunto completo antes do particionamento. A divisão treino/teste foi de 80%/20% com estratificação por classe.

2.2.5 Coluna Vertebral (3C)

O *Dataset Vertebral Column* (BARRETO; NETO, 2011) contém medidas biomecânicas da coluna vertebral de 310 pacientes, descritos por seis atributos numéricos. É avaliado na configuração de três classes (3C): Normal, Hérnia de Disco e Espondilolistese. Os dados são lidos no formato ARFF. A divisão treino/teste foi de 80%/20% com estratificação por classe.

2.3 Desenvolvimento

Para cada conjunto de dados, os três classificadores foram avaliados por meio de **20 realizações independentes** com partições treino/teste geradas por sementes aleatórias de 0 a 19.

Em cada realização:

Particionamento estratificado: o conjunto de dados é dividido de forma estratificada (80%/20%), preservando a proporção de amostras de cada classe nos subconjuntos de treino e teste.

Pré-processamento: a normalização *z-score* é estimada exclusivamente com as amostras de treinamento e aplicada a treino e teste, evitando *data leakage*. Para o *dataset* Dermatology, os valores ausentes de idade são substituídos pela média da coluna calculada sobre o conjunto completo.

Treinamento e predição: cada classificador é treinado nas amostras de treino normalizadas e avalia as amostras de teste.

Ao final das 20 realizações, são reportadas a **acurácia média** $\bar{a}$ e o **desvio padrão** s :

$$\bar{a} = \frac{1}{20} \sum_{r=1}^{20} a_r, \quad s = \sqrt{\frac{1}{20} \sum_{r=1}^{20} (a_r - \bar{a})^2} \quad (2.12)$$

Para a análise qualitativa, é selecionada a realização cuja acurácia do GNB é mais próxima da mediana das 20 realizações.

3 RESULTADOS

Esta seção apresenta os resultados obtidos pelos três classificadores — *Naive Bayes Gaussiano* (GNB), *K Vizinhos Mais Próximos* com $k = 5$ (KNN) e *Distância Mínima ao Centróide* (DMC) — em cada um dos cinco conjuntos de dados, com base em 20 realizações independentes.

A Tabela 2 consolida as acurácias médias e desvios padrão obtidos.

Tabela 2 – Acurácia média (%) e desvio padrão (%) dos classificadores nas 20 realizações independentes.

Dataset	GNB		KNN ($k = 5$)		DMC	
	Média	DP	Média	DP	Média	DP
Artificial I	95,50	3,17	94,42	2,95	95,17	3,29
Iris	94,33	4,36	95,17	3,24	83,50	3,57
Breast Cancer (WDBC)	92,70	2,09	96,15	1,43	92,43	1,89
Dermatology	87,25	2,73	95,99	2,28	96,48	2,46
Coluna Vertebral (3C)	82,34	3,40	79,84	5,19	76,61	3,70

3.1 Dataset Artificial I




Figura 1 – Superfície de decisão do classificador Bayes Gaussiano — Dataset Artificial I

No cenário sintético, os três classificadores apresentaram desempenho semelhante e elevado. O GNB obteve acurácia média de $95,50\% \pm 3,17\%$, seguido pelo DMC com $95,17\% \pm 3,29\%$ e pelo KNN com $94,42\% \pm 2,95\%$. Esse resultado é esperado: o dataset foi gerado a partir de distribuições gaussianas, satisfazendo exatamente as suposições do GNB. O DMC também tem bom desempenho por ser equivalente ao GNB quando as covariâncias são próximas




Figura 2 – Distribuições gaussianas por classe — artificial




Figura 3 – Matrizes de confusão dos três classificadores — Dataset Artificial I

e os priors iguais. Os desvios padrão são similares entre os três classificadores, indicando variabilidade parecida entre as realizações.

3.2 Iris




Figura 4 – Distribuições gaussianas por classe — Iris (atributos *petal length* $\times$ *petal width*)

No *dataset* Iris, o KNN ($95,17\% \pm 3,24\%$) e o GNB ($94,33\% \pm 4,36\%$) apresentaram acurácias próximas e elevadas, enquanto o DMC teve desempenho consideravelmente inferior ($83,50\% \pm 3,57\%$). A maior variabilidade do GNB ($DP = 4,36\%$) pode ser atribuída ao menor




Figura 5 – Superfície de decisão gaussianas por classe — Iris (atributos *petal length* $\times$ *petal width*)




Figura 6 – Matrizes de confusão dos três classificadores — Iris

tamanho do dataset (150 amostras), tornando os resultados mais sensíveis à partição treino/teste. O fraco desempenho do DMC ocorre pois as classes *versicolor* e *virginica* têm centróides próximos no espaço das características, dificultando a separação linear.

3.3 Breast Cancer Wisconsin (WDBC)




Figura 7 – Distribuições gaussianas por classe no espaço PCA 2D — Breast Cancer Wisconsin

No *dataset* Breast Cancer, o KNN (96,15% $\pm$ 1,43%) superou o GNB (92,70% $\pm$ 2,09%)




Figura 8 – Matrizes de confusão dos três classificadores — Breast Cancer Wisconsin

e o DMC ($92,43\% \pm 1,89\%$). A menor acurácia do GNB pode ser explicada pela suposição de independência entre os 30 atributos, que não se sustenta neste dataset — as características derivadas de imagens apresentam forte correlação entre si (e.g., raio, perímetro e área). O KNN, por ser não-paramétrico, não impõe essa restrição e aproveita melhor a estrutura dos dados. O baixo desvio padrão do KNN (1,43%) indica estabilidade robusta nas 20 realizações.

3.4 Dermatology




Figura 9 – Distribuições gaussianas por classe (projecção PCA 2D) — Dermatology




Figura 10 – Matrizes de confusão dos três classificadores — Dermatology

No *dataset* Dermatology, o DMC ($96,48\% \pm 2,46\%$) e o KNN ($95,99\% \pm 2,28\%$) foram superiores ao GNB ($87,25\% \pm 2,73\%$). O GNB apresentou a pior acurácia entre todos os datasets avaliados neste experimento, possivelmente por dois fatores: (1) a maioria dos 34 atributos são variáveis ordinais discretas no intervalo $[0, 3]$, que violam a suposição de distribuição Gaussiana contínua; e (2) a presença de atributos com variância muito baixa ou nula em algumas classes gera instabilidade na estimativa dos parâmetros. O desempenho elevado do DMC é notável, sugerindo que os centróides de cada classe são bem separados no espaço dos atributos.

3.5 Coluna Vertebral (3C)




Figura 11 – Distribuição gaussiana (PCA 2D) e matriz de confusão GBC — Coluna Vertebral (2 Classes)




Figura 12 – Superfície de decisão gaussianas por classe — Vertebral (atributos *Pelvic incidence* $\times$ *lumbar lordosis angle*)

No *dataset* Coluna Vertebral, o GNB ($82,34\% \pm 3,40\%$) superou o KNN ($79,84\% \pm 5,19\%$) e o DMC ($76,61\% \pm 3,70\%$). Este é o único dataset em que o GNB obteve a maior acurácia média. O KNN apresentou o maior desvio padrão ($5,19\%$), indicando alta variabilidade




Figura 13 – Distribuição gaussiana (PCA 2D) e matriz de confusão GBC — Coluna Vertebral (3 Classes)

entre realizações, possivelmente devido ao tamanho moderado do dataset (310 amostras) e ao desequilíbrio entre as classes (Normal: 100, Hérnia: 60, Espondilolistese: 150). O desempenho inferior do DMC evidencia que os centróides das três classes não são suficientemente separados para uma classificação eficaz.

3.6 Comparação com o Trabalho 2 (GBC)

O Trabalho 2 avaliou o *Classificador Bayesiano Gaussiano Multivariado* (GBC), que estima uma matriz de covariância $\hat{\Sigma}_i$ independente para cada classe. O presente trabalho o substitui pelo *Naive Bayes Gaussiano* (GNB), que assume independência condicional entre os atributos, fatorando a verossimilhança como produto de densidades univariadas. Além dessa mudança no classificador principal, duas outras diferenças metodológicas influenciam diretamente os resultados obtidos:

Normalização estendida. No Trabalho 2, a normalização *z-score* foi aplicada apenas ao Breast Cancer (WDBC), cujas escalas são heterogêneas. No Trabalho 3, a mesma normalização foi aplicada a *todos* os conjuntos de dados antes do treinamento. Isso afeta especialmente o DMC e o KNN, cujas métricas de distância são sensíveis à escala dos atributos.

Dataset Artificial I distinto. Os dois trabalhos utilizam conjuntos artificiais com parâmetros diferentes. No Trabalho 2, três classes de 40 amostras são geradas com médias em $[1,5 \ 7,0]$, $[6,5 \ 7,0]$ e $[4,0 \ 3,5]$; no Trabalho 3, classes de 100 amostras são centradas em $[-2 \ -2]$, $[2 \ -2]$ e $[0 \ 2]$. A comparação direta dos resultados nesse dataset, portanto, não é imediata.

A Tabela 3 resume as principais diferenças de acurácia entre os dois trabalhos para o classificador principal e para os classificadores de referência.

Tabela 3 – Acurácia média (%) — comparação entre Trabalho 2 (GBC) e Trabalho 3 (GNB). Os valores de KNN e DMC também refletem diferenças de pré-processamento e sementes.

Dataset	Bayesiano		KNN ($k = 5$)		DMC	
	T2 (GBC)	T3 (GNB)	T2	T3	T2	T3
Artificial I*	99,58	95,50	99,58	94,42	99,86	95,17
Iris	96,50	94,33	95,67	95,17	90,83	83,50
Breast Cancer (WDBC)	94,91	92,70	96,27	96,15	92,68	92,43
Dermatology	89,66	87,25	86,55	95,99	53,72	96,48
Coluna Vertebral (3C)	83,23	82,34	82,42	79,84	75,56	76,61

*Parâmetros e número de amostras distintos entre os dois trabalhos.

4 CONCLUSÕES

Este trabalho avaliou três classificadores — GNB, KNN ($k = 5$) e DMC — em cinco conjuntos de dados distintos, por meio de 20 realizações independentes com particionamento estratificado 80/20.

Os resultados revelam que nenhum classificador domina todos os cenários, e que a escolha do modelo mais adequado depende das características do dataset:

- O **GNB** apresentou desempenho competitivo nos datasets sintético (Artificial I) e Coluna Vertebral, onde as suposições de distribuição Gaussiana e independência entre atributos são razoavelmente satisfeitas. Em contrapartida, o GNB foi o classificador de menor acurácia no Breast Cancer e no Dermatology, datasets com forte correlação entre atributos ou com características discretas ordinais que violam a hipótese Gaussiana.
- O **KNN** foi o melhor classificador nos datasets Iris e Breast Cancer, demonstrando a vantagem de métodos não-paramétricos em problemas com fronteiras de decisão complexas ou atributos correlacionados. No entanto, exibiu a maior variabilidade (Coluna Vertebral) e desempenho inferior ao GNB quando o dataset é pequeno com classes desequilibradas.
- O **DMC** destacou-se no Dermatology, obtendo a maior acurácia média entre todos os classificadores em qualquer dataset. Trata-se de um resultado surpreendente para um método tão simples, sugerindo que as seis classes de doenças eritematoso-escamosas formam agrupamentos bem separados e aproximadamente esféricos no espaço dos atributos. No Iris e no Coluna Vertebral, o DMC foi o classificador de menor desempenho, penalizado pela proximidade entre centróides de classes distintas.

Em termos gerais, a suposição de Gaussianidade do GNB mostrou-se uma limitação relevante em dados reais com atributos correlacionados ou discretos. O KNN, por sua flexibilidade não-paramétrica, tende a superar o GNB nesses cenários, ao custo de maior sensibilidade ao tamanho do dataset. O DMC, apesar de sua simplicidade, revelou-se competitivo quando as classes são bem separadas, sendo equivalente ao GNB sob suposições isotrópicas de covariância.

REFERÊNCIAS

- BARRETO, G.; NETO, A. R. **Vertebral Column**. UCI Machine Learning Repository, 2011. Disponível em: <<https://doi.org/10.24432/C5K89B>>.
- BISHOP, C. M. **Pattern Recognition and Machine Learning**. [S.l.]: Springer, 2006.
- CANH, T. N.; HOANGVAN, X. Machine learning-based malicious vehicle detection for security threats and attacks in vehicle ad-hoc network (VANET) communications. Hanoi, Vietnam.
- DUDA, R. O.; HART, P. E.; STORK, D. G. **Pattern Classification**. 2. ed. [S.l.]: Wiley-Interscience, 2001.
- FISHER, R. **Íris**. UCI Machine Learning Repository, 1988. Dataset com 310 instâncias e 6 atributos biomecânicos para classificação de patologias ortopédicas em 3 classes (normal, hérnia de disco, espondilolistese) ou 2 classes (normal ou anormal). Doado em 08/08/2011. Disponível em: <<https://doi.org/10.24432/C5K89B>>.
- ILTER, N.; GUVENIR, H. **Dermatology**. UCI Machine Learning Repository, 1997. Disponível em: <<https://doi.org/10.24432/C56C76>>.
- MANGALA, N.; RANGWALA, M.; AISHWARYA, S.; REDDY, B. E.; BUYYA, R.; VENGOPAL, K. R.; IYENGAR, S. S.; PATNAIK, L. M. Differential privacy for secure machine learning in healthcare IoT-cloud systems. 2025. Submitted 11 Dec 2025; revised 2 Apr 2026 (v3). Disponível em: <<https://arxiv.org/abs/2512.10426>>.
- WOLBERG, W.; MANGASARIAN, O.; STREET, N.; STREET, W. **Breast Cancer Wisconsin (Diagnostic)**. UCI Machine Learning Repository, 1995. Dataset com 569 instâncias e 30 atributos para diagnóstico de câncer de mama em 2 classes: maligno e benigno. Doado em 31/10/1995. Disponível em: <<https://archive.ics.uci.edu/dataset/17/breast+cancer+wisconsin+diagnostic>>.