



INSTITUTO FEDERAL DE EDUCAÇÃO, CIÊNCIA E TECNOLOGIA DO CEARÁ
IFCE *CAMPUS* FORTALEZA

OSVALDO SOARES LANDIM JUNIOR

**RELATÓRIO DO CLASSIFICADOR BAYESIANO GAUSSIANO COM BASE NOS
DISCRIMINANTES LINEARES E QUADRÁTICOS.**

FORTALEZA - CE

1 INTRODUÇÃO

A Teoria de Decisão de Bayes estabelece um arcabouço ótimo para a classificação supervisionada isso quando as distribuições de probabilidade condicionais às classes que são conhecidas (DUDA; HART; STORK, 2001). Nessa abordagem, a regra de decisão consiste em atribuir um padrão $\vec{x}$ à classe cuja probabilidade a posteriori é máxima:

$$\hat{\omega}(\vec{x}) = \arg \max_{\omega_i} P(\omega_i | \vec{x}) = \arg \max_{\omega_i} p(\vec{x} | \omega_i) P(\omega_i) \quad (1.1)$$

Nessa equação ao assumir que os dados de cada classe ω_i que seguem uma distribuição Gaussiana multivariada com vetor de médias μ_i e matriz de uma covariância Σ_i , podem obter uma família de classificadores cujas funções discriminantes é consequentemente uma superfícies cujas as suas decisão dependem diretamente de uma estrutura imposta por Σ_i (BISHOP, 2006).

Quando todas as classes compartilham da mesma matriz de covariância ($\Sigma_i = \Sigma$ para todo i), os termos quadráticos se cancelam na mesma comparação entre classes, e as superfícies de decisão resultantes são **hiperplanos** assim configurando os denominados **discriminantes lineares** (LDA, do inglês *Linear Discriminant Analysis*). Nesse sentido quando as matrizes de covariância são distintas por classe, os termos quadráticos não se cancelam e as fronteiras tornam-se **superfícies quádricas** elipses, hipérboles ou parábolas em 2D assim caracterizando os **discriminantes quadráticos** como (QDA, *Quadratic Discriminant Analysis*) (THEODORIDIS; KOUTROUMBAS, 2009). Além desses dois casos gerais, a literatura descreve situações especiais obtidas ao impor restrições adicionais à matriz de covariância que são covariâncias esféricas iguais, que recuperam o Classificador de Distância Mínima ao Centróide (DMC) e covariâncias diagonais por classe, equivalentes ao Classificador Naive Bayes Gaussiano (GNB) (BISHOP, 2006).

Com tudo a análise dessas diferentes hipóteses é fundamental para compreender o compromisso entre a flexibilidade do modelo e o risco de superajuste, especialmente em cenários com amostras limitadas por classe. No entanto um modelo com a covariâncias completamente distintas (QDA) é mais expressivo, porém exige a estimação de $d(d+1)/2$ que é parâmetros adicionais por classe, que tornando-se suscetíveis a *overfitting*, quando n_i é pequeno em relação à dimensionalidade d , LDA, ao impor uma covariância comum, reduz significativamente o número de parâmetros e tende a generalizar melhor em *datasets* de menor porte (DUDA; HART; STORK, 2001).

Portanto, este relatório propõe implementar o classificador Bayesiano Gaussiano sob quatro hipóteses distintas sobre as matrizes de covariância das classes QDA (covariâncias distintas por classe), LDA (covariância *pooled* comum), DMC (covariâncias esféricas iguais) e GNB (covariâncias diagonais por classe) e comparar os classificadores resultantes aplicados a cinco conjuntos de dados: Flor Íris, Coluna Vertebral, Breast Cancer, Dermatology e Artificial, avaliando o desempenho de cada configuração por meio de métricas de acurácia e análise qualitativa das superfícies de decisão obtidas.

2 METODOLOGIA

2.1 Funções Discriminantes Bayesianas

Assumindo que os dados de cada classe ω_i , $i = 1, \dots, c$, seguem uma distribuição Gaussiana multivariada de dimensão d :

$$p(\vec{x} | \omega_i) = \frac{1}{(2\pi)^{d/2} |\Sigma_i|^{1/2}} \exp\left(-\frac{1}{2}(\vec{x} - \mu_i)^\top \Sigma_i^{-1}(\vec{x} - \mu_i)\right) \quad (2.1)$$

a função discriminante logarítmica de cada classe é definida como:

$$g_i(\vec{x}) = \log P(\omega_i) - \frac{1}{2} \log |\Sigma_i| - \frac{1}{2}(\vec{x} - \mu_i)^\top \Sigma_i^{-1}(\vec{x} - \mu_i) \quad (2.2)$$

e a regra de decisão é $\hat{\omega}(\vec{x}) = \arg \max_i g_i(\vec{x})$. A forma da superfície de decisão entre duas classes ω_i e ω_j é determinada pelo conjunto $\{\vec{x} : g_i(\vec{x}) = g_j(\vec{x})\}$, cuja natureza geométrica depende inteiramente da estrutura de Σ_i (THEODORIDIS; KOUTROUMBAS, 2009).

2.2 Casos Especiais das Matrizes de Covariância

2.2.1 Caso 1 — Covariâncias Distintas por Classe (QDA)

No caso mais geral, cada classe possui sua própria matriz de covariância Σ_i , estimada por Máxima Verossimilhança (MLE). A função discriminante (2.2) mantém todos os seus termos, e a fronteira de decisão entre quaisquer duas classes é uma **superfície quádrica**. Este caso é denominado Análise Discriminante Quadrática (QDA) e é o mais flexível, porém exige a estimação de $c \cdot d(d+1)/2$ parâmetros de covariância (BISHOP, 2006).

2.2.2 Caso 2 — Covariância Comum a Todas as Classes (LDA)

Impondo $\Sigma_i = \Sigma$ para todo i , os termos $-\frac{1}{2} \log |\Sigma_i|$ e $-\frac{1}{2} \vec{x}^\top \Sigma_i^{-1} \vec{x}$ tornam-se idênticos para todas as classes e se cancelam na comparação $g_i(\vec{x}) - g_j(\vec{x})$. A função discriminante reduz-se a uma forma **linear** em $\vec{x}$:

$$g_i(\vec{x}) = \vec{x}^\top \Sigma^{-1} \mu_i - \frac{1}{2} \mu_i^\top \Sigma^{-1} \mu_i + \log P(\omega_i) \quad (2.3)$$

produzindo fronteiras de decisão que são **hiperplanos**. A covariância comum Σ é estimada pela covariância *pooled*, definida como a média ponderada das covariâncias de cada classe:

$$\hat{\Sigma} = \frac{1}{n} \sum_{i=1}^c n_i \hat{\Sigma}_i \quad (2.4)$$

onde n_i é o número de amostras da classe ω_i e $n = \sum_i n_i$ é o total de amostras de treinamento (DUDA; HART; STORK, 2001).

2.2.3 Caso 3 — Covariâncias Esféricas Iguais ($\Sigma_i = \sigma^2 \mathbf{I}$)

Caso particular do LDA em que a covariância comum é múltipla da identidade: $\Sigma = \sigma^2 \mathbf{I}$. A distância de Mahalanobis reduz-se à distância Euclidiana ao quadrado, e a fronteira de decisão entre ω_i e ω_j torna-se um **hiperplano perpendicular** ao segmento que une os centróides μ_i e μ_j , passando pelo ponto médio ponderado pelos priors. Quando os priors são iguais, este caso recupera exatamente o **Classificador de Distância Mínima ao Centróide (DMC)** (JAMES *et al.*, 2021).

2.2.4 Caso 4 — Covariâncias Diagonais por Classe (GNB)

Cada Σ_i é restrita a ser diagonal: $\Sigma_i = \text{diag}(\sigma_{i1}^2, \dots, \sigma_{id}^2)$. Isso equivale a assumir independência condicional entre os atributos dado o rótulo de classe, fatorando a verossimilhança como produto de densidades univariadas:

$$p(\vec{x} | \omega_i) = \prod_{j=1}^d \frac{1}{\sqrt{2\pi} \sigma_{ij}^2} \exp\left(-\frac{(x_j - \mu_{ij})^2}{2\sigma_{ij}^2}\right) \quad (2.5)$$

Este caso corresponde ao **Classificador Naive Bayes Gaussiano (GNB)**, analisado no Trabalho 3. As fronteiras de decisão são superfícies quádricas, porém com orientação alinhada aos eixos das características (BISHOP, 2006).

2.3 Estimação dos Parâmetros

Para todos os casos, os vetores de médias são estimados por MLE:

$$\hat{\mu}_i = \frac{1}{n_i} \sum_{k \in \omega_i} \vec{x}_k \quad (2.6)$$

As matrizes de covariância por classe são estimadas como:

$$\hat{\Sigma}_i = \frac{1}{n_i} \sum_{k \in \omega_i} (\vec{x}_k - \hat{\mu}_i)(\vec{x}_k - \hat{\mu}_i)^\top \quad (2.7)$$

Para estabilidade numérica na inversão matricial, aplica-se regularização de Tikhonov adicionando $\varepsilon \mathbf{I}$ à diagonal antes da inversão, com $\varepsilon = 10^{-6}$ (BISHOP, 2006). As probabilidades a priori são estimadas pela frequência relativa de cada classe no conjunto de treinamento:

$$P(\omega_i) = \frac{n_i}{n} \quad (2.8)$$

2.4 Conjuntos de Dados

Os quatro classificadores foram avaliados nos mesmos cinco conjuntos de dados utilizados nos trabalhos anteriores. A Tabela 1 apresenta um resumo das características de cada *dataset*.

Tabela 1 – Resumo dos conjuntos de dados utilizados nos experimentos.

Dataset	Amostras	Features	Classes	Divisão
Artificial I	300	2	3	80/20 (estratificado)
Iris	150	4	3	80/20 (estratificado)
Breast Cancer (WDBC)	569	30	2	80/20 (estratificado)
Dermatology	366	34	6	80/20 (estratificado)
Coluna Vertebral (3C)	310	6	3	80/20 (estratificado)

As características de cada conjunto de dados são as mesmas descritas nos trabalhos anteriores: o Dataset Artificial I foi gerado sinteticamente a partir de distribuições gaussianas multivariadas, o Dataset Iris (FISHER, 1988) contém medidas morfológicas de flores; o Breast Cancer Wisconsin WDBC (WOLBERG et al., 1995) reúne características de biópsias de tumor de mama; o Dataset Dermatology (ILTER; GUVENIR, 1997) descreve doenças eritematoso-escamosas da pele; e o Dataset Coluna Vertebral (BARRETO; NETO, 2011) contém medidas biomecânicas da coluna em três classes.

2.5 Realização dos testes

Para cada conjunto de dados, os quatro classificadores QDA, LDA, DMC e GNB foram avaliados por meio de 20 realizações independentes com partições treino/teste geradas por sementes aleatórias de 0 a 19. Em cada realização:

Particionamento estratificado: o conjunto de dados é dividido de forma estratificada (80%/20%), preservando a proporção de amostras de cada classe nos subconjuntos de treino e teste.

Pré-processamento: a normalização *z-score* é estimada exclusivamente com as amostras de treinamento e aplicada a treino e teste, evitando *data leakage*. Para o Dataset Dermatology, os valores ausentes de idade são substituídos pela média da coluna calculada sobre o conjunto completo antes do particionamento.

Treinamento e predição: cada classificador é treinado nas amostras de treino normalizadas e avalia as amostras de teste.

Ao final das 20 realizações, são reportadas a acurácia média $\bar{a}$ e o desvio padrão s :

$$\bar{a} = \frac{1}{20} \sum_{r=1}^{20} a_r, \quad s = \sqrt{\frac{1}{20} \sum_{r=1}^{20} (a_r - \bar{a})^2} \quad (2.9)$$

Para a análise qualitativa, é selecionada a realização cuja acurácia do QDA é mais próxima da mediana das 20 realizações. Sobre essa realização representativa são geradas a matriz de confusão e a visualização das superfícies de decisão e das gaussianas por classe. Nos *datasets* com mais de duas dimensões, a visualização é realizada mediante projeção dos dados nos dois primeiros componentes principais (PCA).

3 RESULTADOS

Este trabalho implementa o classificador Bayesiano Gaussiano nas formas linear (LDA) e quadrática (QDA), investigando quatro situações distintas para as matrizes de covariância das classes, conforme descrito na Tabela 2.

Tabela 2 – Situações de covariância investigadas.

Caso	Modelo	Matriz Σ	Fronteira
1	QDA Full	Σ_k individual e completa	Quadrática geral
2	LDA	Σ pooled compartilhada	Linear
3	QDA Diagonal	$\text{diag}(\Sigma_k)$ — sem correlação	Quadrática
4	QDA Isotrópica	$\sigma_k^2 \mathbf{I}$ — variância escalar	Esférica/circular
+	QDA Regularized	$\Sigma_k + \lambda \mathbf{I}$ maior	Quadrática
+	QDA Pooled $\alpha=0.5$	$\alpha \Sigma_k + (1 - \alpha) \Sigma_{\text{pool}}$	Quadrática

Todos os experimentos usaram **20 realizações** com divisão aleatória treino/teste (80%/20%), e os resultados são comparados também com KNN ($k = 5$) e DMC (Distância Mínima ao Centroide).

3.1 Resultados por Dataset

3.1.1 Dataset Artificial I

Descrição: 300 amostras, 2 atributos, 3 classes gaussianas artificialmente geradas com diferentes matrizes de covariância.

Tabela 3 – Resultados — Artificial I (20 realizações, teste 20%).

Classificador	Média	DP	Mín	Máx
QDA Isotrópica (Caso 4)	96,42%	2,70%	88,33%	100,00%
LDA (Caso 2)	96,25%	3,07%	86,67%	100,00%
QDA Full (Caso 1)	96,25%	2,98%	86,67%	100,00%
QDA Diagonal (Caso 3)	96,25%	2,98%	86,67%	100,00%
QDA Pooled $\alpha=0.5$	96,25%	2,98%	86,67%	100,00%
DMC	96,08%	2,95%	88,33%	100,00%
QDA Regularized	96,00%	2,95%	86,67%	100,00%
KNN $k=5$	95,58%	3,17%	88,33%	100,00%

Os classificadores apresentaram desempenho muito similar, com médias entre 95,58% e 96,42%. A QDA Isotrópica (Caso 4) obteve a maior média, o que é coerente com o fato de o

dataset ter sido gerado com covariâncias próximas de $\sigma^2 \mathbf{I}$.




Figura 1 – Superfície de decisão do discriminante quadrático — Dataset Artificial I




Figura 2 – Matrizes de confusão dos três classificadores — Dataset Artificial I

3.1.2 Dataset Breast Cancer (WDBC)

Descrição: 569 amostras, 30 atributos, 2 classes (Benigno/Maligno).

Com 30 atributos e apenas 2 classes, o LDA se destacou entre os Bayesianos (96,58%), superando todas as variações de QDA. A QDA Full e a Diagonal tiveram desempenho idêntico

Tabela 4 – Resultados — Breast Cancer (20 realizações, teste 20%).

Classificador	Média	DP	Mín	Máx
KNN $k=5$	97,06%	1,62%	94,74%	99,12%
LDA (Caso 2)	96,58%	1,62%	92,98%	100,00%
QDA Regularized	96,36%	1,58%	92,98%	99,12%
QDA Pooled $\alpha=0.5$	95,13%	2,23%	90,35%	98,25%
QDA Full (Caso 1)	94,39%	2,08%	90,35%	98,25%
QDA Diagonal (Caso 3)	94,39%	2,08%	90,35%	98,25%
DMC	94,12%	2,11%	89,47%	98,25%
QDA Isotrópica (Caso 4)	92,68%	2,41%	88,60%	98,25%

(94,39%), indicando que as correlações entre atributos não agregaram informação relevante neste caso. A QDA Isotrópica foi a pior, pois o dataset possui atributos com escalas e variâncias muito distintas, tornando a hipótese $\Sigma_k = \sigma_k^2 \mathbf{I}$ inadequada.




Figura 3 – Superfície de decisão por classe no espaço PCA 2D — Breast Cancer Wisconsin




Figura 4 – Matrizes de confusão dos três classificadores — Breast Cancer Wisconsin

3.1.3 Dataset Dermatology

Descrição: 358 amostras, 34 atributos, 6 classes de doenças dermatológicas.

Tabela 5 – Resultados — Dermatology (20 realizações, teste 20%).

Classificador	Média	DP	Mín	Máx
QDA Pooled $\alpha=0.5$	96,81%	1,65%	94,44%	100,00%
QDA Isotrópica (Caso 4)	96,39%	1,67%	94,44%	98,61%
LDA (Caso 2)	96,25%	1,82%	91,67%	98,61%
DMC	96,04%	1,47%	93,06%	98,61%
KNN $k=5$	95,49%	2,10%	90,28%	98,61%
QDA Regularized	91,60%	3,47%	84,72%	98,61%
QDA Full (Caso 1)	87,22%	2,62%	83,33%	91,67%
QDA Diagonal (Caso 3)	87,22%	2,62%	83,33%	91,67%

O QDA Pooled com $\alpha=0.5$ foi o melhor classificador (96,81%), combinando covariância individual e pooled. Notavelmente, o QDA Full e o Diagonal tiveram os piores resultados entre os Bayesianos (87,22%), o que indica *overfitting*: com 34 atributos e poucas amostras por classe, estimar Σ_k completa é instável. Modelos mais simples (LDA, Pooled) generalizaram melhor.




Figura 5 – superfícies decisão por classe (projeção PCA 2D) — Dermatology

3.1.4 Dataset Íris

Descrição: 150 amostras, 4 atributos, 3 classes de flores.

O LDA foi o melhor classificador (97,67%), seguido do QDA Pooled. Este resultado clássico da Íris confirma que as classes têm estrutura aproximadamente linear, favorecendo o discriminante linear. A QDA Isotrópica teve o pior desempenho e maior variância (DP = 7,25%),




Figura 6 – Matrizes de confusão dos três classificadores — Dermatology

Tabela 6 – Resultados — Íris (20 realizações, teste 20%).

Classificador	Média	DP	Mín	Máx
LDA (Caso 2)	97,67%	2,13%	93,33%	100,00%
QDA Pooled $\alpha=0.5$	97,50%	2,07%	93,33%	100,00%
QDA Regularized	96,33%	2,56%	90,00%	100,00%
KNN $k=5$	94,67%	3,06%	86,67%	100,00%
QDA Full (Caso 1)	94,33%	3,00%	86,67%	100,00%
QDA Diagonal (Caso 3)	94,33%	3,00%	86,67%	100,00%
DMC	85,67%	6,67%	73,33%	96,67%
QDA Isotrópica (Caso 4)	84,50%	7,25%	70,00%	96,67%

pois as classes da Íris possuem atributos com correlações e escalas distintas, contradizendo a hipótese de isotropia.




Figura 7 – Superfície de decisão por classe — Iris (atributos *petal length* $\times$ *petal width*)




Figura 8 – Matrizes de confusão dos três classificadores — Iris

3.1.5 Dataset Coluna Vertebral

Descrição: 310 amostras, 6 atributos biomecânicos, 3 classes (Hérnia, Normal, Espondilolistese).

Tabela 7 – Resultados — Coluna Vertebral (20 realizações, teste 20%).

Classificador	Média	DP	Mín	Máx
QDA Full (Caso 1)	84,27%	3,10%	77,42%	88,71%
QDA Regularized	84,27%	3,18%	77,42%	88,71%
QDA Diagonal (Caso 3)	83,23%	4,49%	74,19%	90,32%
QDA Pooled $\alpha=0.5$	80,97%	3,48%	72,58%	87,10%
LDA (Caso 2)	80,48%	3,98%	69,35%	87,10%
KNN $k=5$	79,03%	3,46%	72,58%	85,48%
QDA Isotrópica (Caso 4)	77,74%	4,38%	70,97%	87,10%
DMC	76,69%	5,16%	62,90%	82,26%

Para a Coluna Vertebral, as variações de QDA superaram o LDA, com QDA Full e QDA Regularized empatados em primeiro (84,27%). Isso indica que as classes possuem covariâncias diferentes entre si, o que penaliza o LDA (que assume covariâncias iguais). O desvio padrão mais alto do QDA Diagonal (4,49%) sugere instabilidade nesse dataset.

3.2 Comparação Geral entre Datasets

A Tabela 8 resume o melhor classificador e a acurácia média para cada dataset.




Figura 9 – Superfície de descisão por classe — Vertebral (atributos *Pelvic incidence* $\times$ *lumbar lordosis angle*)

Tabela 8 – Resumo geral — melhor classificador por dataset.

Dataset	Melhor Classificador	Tipo	Média
Artificial I	QDA Isotrópica (Caso 4)	Bayesiano	96,42%
Breast Cancer	KNN $k=5$	Não-param.	97,06%
Dermatology	QDA Pooled $\alpha=0.5$	Bayesiano	96,81%
Íris	LDA (Caso 2)	Bayesiano	97,67%
Coluna Vertebral	QDA Full (Caso 1)	Bayesiano	84,27%

3.3 Conclusões

Com base nos experimentos realizados, as seguintes conclusões podem ser extraídas:

Sobre as variações de covariância

- **Caso 1 — QDA Full (Σ_k individual):** melhor quando as classes possuem estruturas de covariância genuinamente distintas (Coluna Vertebral). Entretanto, é suscetível a *overfitting* em datasets com muitos atributos e poucas amostras por classe (Dermatology).
- **Caso 2 — LDA (Σ pooled):** excelente desempenho em datasets com separação aproximadamente linear entre classes (Íris, Breast Cancer). Mais estável que o QDA Full quando o número de atributos é alto em relação ao número de amostras.




Figura 10 – matriz de confusão — Coluna Vertebral (3 Classes)

- **Caso 3 — QDA Diagonal:** equivalente ao Naive Bayes Gaussiano. Ignora correlações entre atributos, o que é prejudicial em dados com forte dependência entre variáveis. Em Dermatology e Breast Cancer, igualou o QDA Full, sugerindo que as correlações têm pouco impacto adicional nesses casos.
- **Caso 4 — QDA Isotrópica ($\sigma_k^2 \mathbf{I}$):** modelo mais restritivo. Funcionou surpreendentemente bem no Artificial I (cujas classes foram geradas com covariâncias próximas à identidade), mas foi o pior na Íris e no Breast Cancer, onde as variâncias por atributo são heterogêneas.
- **QDA Pooled ($\alpha=0.5$):** interpolação entre LDA e QDA Full, foi o melhor no Dermatology e competitivo nos demais. É uma boa escolha quando há dúvida sobre qual hipótese de covariância adotar.
- **QDA Regularized:** comportamento similar ao QDA Full com maior estabilidade numérica. Útil quando Σ_k é mal-condicionada.

Comparação com classificadores anteriores (KNN e DMC)

- O **KNN** ($k=5$) foi competitivo em todos os datasets, sendo o melhor no Breast Cancer (97,06%). Por não assumir distribuição paramétrica, adapta-se bem a fronteiras complexas.

- O **DMC** teve desempenho inferior aos Bayesianos na maioria dos datasets, especialmente na Íris (85,67%) e Coluna Vertebral (76,69%), confirmando sua limitação em dados com classes não esféricas.
- Os classificadores Bayesianos Gaussianos superaram o DMC em todos os datasets e foram competitivos com o KNN, com a vantagem de oferecer interpretação probabilística e menor custo computacional em predição.

A escolha da estrutura de covariância deve levar em conta: (i) o número de amostras por classe em relação à dimensionalidade, (ii) a presença ou ausência de correlações relevantes entre atributos, e (iii) a homogeneidade das covariâncias entre classes. Uma estratégia prática é testar múltiplas variações via validação cruzada, como realizado neste trabalho.

REFERÊNCIAS

BISHOP, C. M. **Pattern Recognition and Machine Learning**. [S.l.]: Springer, 2006.

DUDA, R. O.; HART, P. E.; STORK, D. G. **Pattern Classification**. 2. ed. [S.l.]: Wiley-Interscience, 2001.

JAMES, G.; WITTEN, D.; HASTIE, T.; TIBSHIRANI, R. **An Introduction to Statistical Learning: with Applications in R**. 2. ed. New York: Springer, 2021. Disponível em: <<https://www.statlearning.com>>.

THEODORIDIS, S.; KOUTROUMBAS, K. **Pattern Recognition**. 4. ed. [S.l.]: Academic Press, 2009.