



INSTITUTO FEDERAL DE EDUCAÇÃO, CIÊNCIA E TECNOLOGIA DO CEARÁ
IFCE *CAMPUS* FORTALEZA

OSVALDO SOARES LANDIM JUNIOR

RELATÓRIO DO MODELOS DE MISTURAS DE GAUSSIANAS

FORTALEZA - CE

1 INTRODUÇÃO

A modelagem probabilística de dados multivariados constitui um dos fundamentos da aprendizagem de máquina supervisionada e não supervisionada. Quando se assume que cada classe segue uma distribuição Gaussiana multivariada, obtém-se uma família de classificadores cuja regra de decisão é derivada diretamente do Teorema de Bayes (BISHOP, 2006; DUDA; HART; STORK, 2001):

$$\hat{\omega}(\mathbf{x}) = \arg \max_{\omega_i} P(\omega_i | \mathbf{x}) = \arg \max_{\omega_i} p(\mathbf{x} | \omega_i) P(\omega_i). \quad (1.1)$$

Contudo, a hipótese de unimodalidade Gaussiana por classe nem sempre é suficiente para capturar a verdadeira estrutura dos dados. Em situações em que cada classe apresenta subpopulações distintas agrupamentos, modos múltiplos ou formas não convexas um único Gaussiano pode ser incapaz de descrever adequadamente a densidade condicional $p(\mathbf{x} | \omega_i)$ (THEODORIDIS; KOUTROUMBAS, 2009).

Uma generalização natural consiste em modelar a densidade de cada classe como uma *mistura de Gaussianas* (Gaussian Mixture Model, GMM), expressa por uma combinação linear de J componentes:

$$p(\mathbf{x}) = \sum_{j=1}^J p(\mathbf{x} | j) P_j, \quad \sum_{j=1}^J P_j = 1, \quad \int_{\mathbf{x}} p(\mathbf{x} | j) d\mathbf{x} = 1, \quad (1.2)$$

onde P_j é o peso (prior) do j -ésimo componente e $p(\mathbf{x} | j)$ é a densidade Gaussiana multivariada associada a esse componente (BISHOP, 2006). As misturas de Gaussianas são atraentes por dois motivos principais: do ponto de vista teórico, podem aproximar arbitrariamente bem qualquer densidade contínua para um número suficiente de componentes J e parâmetros adequados (THEODORIDIS; KOUTROUMBAS, 2009); do ponto de vista prático, mantêm uma interpretação probabilística clara que permite calcular posteriors, tomar decisões ótimas de Bayes e quantificar incerteza.

A estimação dos parâmetros de uma GMM são os vetores de médias μ_j , as matrizes de covariância Σ_j e os pesos P_j não são direta. A dificuldade central é que os rótulos de componente de cada amostra são *variáveis latentes*: não se observa de qual componente cada observação foi gerada. Isso configura o chamado problema de *dados incompletos*, para o qual o algoritmo de Expectativa-Maximização (EM) é a solução padrão (BISHOP, 2006; DUDA; HART; STORK, 2001). O algoritmo EM alterna entre dois passos: o passo E (*Expectation*), que calcula as responsabilidades da probabilidades posteriores de cada amostra pertencer a cada componente e

assim o passo M (*Maximization*), que reestima os parâmetros maximizando a verossimilhança esperada (THEODORIDIS; KOUTROUMBAS, 2009).

No contexto de classificação supervisionada, o uso de GMMs por classe generaliza os discriminantes clássicos. A Análise Discriminante Linear (LDA) e a Análise Discriminante Quadrática (QDA) correspondem a casos especiais em que cada classe é modelada por um único componente Gaussiano com, respectivamente, covariância compartilhada ou covariância própria (DUDA; HART; STORK, 2001). Ao substituir esse único componente por uma mistura, o classificador resultante pode representar fronteiras de decisão mais complexas, acomodando classes com geometria intrinsecamente multimodal (BISHOP, 2006).

Portanto, este relatório estende a análise dos classificadores Bayesianos Gaussianos investigados anteriormente (QDA, LDA, DMC e GNB) incorporando a perspectiva das Misturas de Gaussianas como modelo mais geral de densidade. O objetivo é comparar o desempenho dos classificadores baseados em componente único com a flexibilidade oferecida pelas GMMs, avaliando o compromisso entre capacidade expressiva e risco de sobreajuste nos cinco conjuntos de dados utilizados: Artificial I, Íris, Breast Cancer (WDBC), Dermatology e Coluna Vertebral.

2 METODOLOGIA

2.1 Modelo de Mistura de Gaussianas (GMM)

Seja $\mathbf{x} \in \mathbb{R}^d$ um vetor de características. O Modelo de Mistura de Gaussianas representa a densidade de probabilidade de $\mathbf{x}$ como

$$p(\mathbf{x}) = \sum_{j=1}^J P_j \mathcal{N}(\mathbf{x}; \mu_j, \Sigma_j), \quad (2.1)$$

onde $\mathcal{N}(\mathbf{x}; \mu_j, \Sigma_j)$ denota a densidade Gaussiana multivariada de média $\mu_j \in \mathbb{R}^d$ e matriz de covariância $\Sigma_j \in \mathbb{R}^{d \times d}$, e os pesos satisfazem $P_j > 0$, $\sum_{j=1}^J P_j = 1$ (BISHOP, 2006). No contexto de classificação supervisionada, uma GMM separada é ajustada para cada classe ω_i , de modo que a verossimilhança condicional é

$$p(\mathbf{x} | \omega_i) = \sum_{j=1}^{J_i} P_{ij} \mathcal{N}(\mathbf{x}; \mu_{ij}, \Sigma_{ij}), \quad (2.2)$$

onde J_i é o número de componentes da classe ω_i (THEODORIDIS; KOUTROUMBAS, 2009).

2.2 Algoritmo Expectativa-Maximização (EM)

A estimação dos parâmetros $\theta_i = \{P_{ij}, \mu_{ij}, \Sigma_{ij}\}_{j=1}^{J_i}$ de cada GMM por classe é realizada via algoritmo EM (BISHOP, 2006; DUDA; HART; STORK, 2001). O algoritmo trata os índices de componente z_{kj} indicando de qual componente j a k -ésima amostra da classe ω_i foi gerada como variáveis latentes, constituindo assim um problema de *dados incompletos* (THEODORIDIS; KOUTROUMBAS, 2009).

Dado um conjunto de amostras de treinamento $\{\mathbf{x}_k\}_{k \in \omega_i}$ de tamanho n_i , o algoritmo EM itera entre dois passos até a convergência da log-verossimilhança (BISHOP, 2006):

2.2.1 Passo E — Expectation

Para cada amostra $\mathbf{x}_k$ e componente j , calcula-se a *responsabilidade* (probabilidade posterior de pertença ao componente j):

$$r_{kj} = \frac{P_{ij} \mathcal{N}(\mathbf{x}_k; \mu_{ij}, \Sigma_{ij})}{\sum_{\ell=1}^{J_i} P_{i\ell} \mathcal{N}(\mathbf{x}_k; \mu_{i\ell}, \Sigma_{i\ell})}. \quad (2.3)$$

2.2.2 Passo M — Maximization

Com as responsabilidades fixas, reestimam-se os parâmetros de cada componente j maximizando a log-verossimilhança esperada (Q-função) (DUDA; HART; STORK, 2001):

$$N_j = \sum_{k=1}^{n_i} r_{kj}, \quad (2.4)$$

$$\hat{P}_{ij} = \frac{N_j}{n_i}, \quad (2.5)$$

$$\hat{\mu}_{ij} = \frac{1}{N_j} \sum_{k=1}^{n_i} r_{kj} \mathbf{x}_k, \quad (2.6)$$

$$\hat{\Sigma}_{ij} = \frac{1}{N_j} \sum_{k=1}^{n_i} r_{kj} (\mathbf{x}_k - \hat{\mu}_{ij})(\mathbf{x}_k - \hat{\mu}_{ij})^\top + \varepsilon \mathbf{I}, \quad (2.7)$$

onde o termo $\varepsilon \mathbf{I}$ (com $\varepsilon = 10^{-6}$) é a regularização de Tikhonov adicionada para garantir a invertibilidade numérica de $\hat{\Sigma}_{ij}$ (BISHOP, 2006). Os passos E e M são repetidos até que a variação relativa da log-verossimilhança seja inferior a 10^{-4} ou até atingir o máximo de 200 iterações.

2.3 Inicialização pelo K-Means

Para reduzir a sensibilidade do EM a mínimos locais, os parâmetros iniciais são obtidos pelo algoritmo K-Means executado sobre as amostras de cada classe (THEODORIDIS; KOUTROUMBAS, 2009). As médias iniciais $\mu_{ij}^{(0)}$ são os centróides do K-Means; as covariâncias iniciais $\Sigma_{ij}^{(0)}$ são as covariâncias empíricas de cada cluster; e os pesos iniciais $P_{ij}^{(0)}$ são as frequências relativas dos clusters.

2.4 Regra de Classificação

Após o ajuste de uma GMM por classe, a classificação de uma nova amostra $\mathbf{x}$ é realizada pela regra de Bayes (BISHOP, 2006; DUDA; HART; STORK, 2001):

$$\hat{\omega}(\mathbf{x}) = \arg \max_{\omega_i} \log P(\omega_i) + \log p(\mathbf{x} | \omega_i), \quad (2.8)$$

onde $p(\mathbf{x} | \omega_i)$ é dado pela equação (2.2) e $P(\omega_i)$ é estimado pela frequência relativa de cada classe no conjunto de treinamento.

2.5 Seleção do Número de Componentes

O número de componentes J_i é um hiperparâmetro que controla o compromisso entre capacidade expressiva e risco de sobreajuste (THEODORIDIS; KOUTROUMBAS, 2009). São investigados valores $J \in \{1, 2, 3, 4, 5\}$, onde $J = 1$ recupera o classificador QDA clássico. A seleção é realizada por validação cruzada estratificada com 5 folds sobre o conjunto de treinamento, minimizando o erro de classificação médio.

2.6 Conjuntos de Dados

Os classificadores são avaliados nos mesmos cinco conjuntos de dados dos experimentos anteriores, cujas características estão resumidas na Tabela 1.

Tabela 1 – Resumo dos conjuntos de dados utilizados.

Dataset	Amostras	Features	Classes	Divisão
Artificial I	300	2	3	80/20 (estratif.)
Íris	150	4	3	80/20 (estratif.)
Breast Cancer (WDBC)	569	30	2	80/20 (estratif.)
Dermatology	366	34	6	80/20 (estratif.)
Coluna Vertebral (3C)	310	6	3	80/20 (estratif.)

2.7 Protocolo Experimental

Para cada conjunto de dados e cada valor de J , são realizadas 20 realizações independentes com sementes aleatórias de 0 a 19, seguindo o mesmo protocolo dos trabalhos anteriores. Em cada realização:

1. **Particionamento estratificado** (80%/20%), preservando a proporção de amostras por classe em treino e teste.
2. **Pré-processamento:** normalização z-score estimada exclusivamente sobre o conjunto de treinamento e aplicada a treino e teste, evitando *data leakage*. Valores ausentes de idade no Dermatology são imputados pela média da coluna calculada antes do particionamento.
3. **Treinamento:** ajuste de uma GMM por classe via EM inicializado pelo K-Means.
4. **Predição e avaliação:** classificação do conjunto de teste pela regra (2.8) e cômputo da acurácia.

Ao final das 20 realizações, reportam-se a acurácia média $\bar{a}$ e o desvio padrão s , conforme a equação

$$\bar{a} = \frac{1}{20} \sum_{r=1}^{20} a_r, \quad s = \sqrt{\frac{1}{20} \sum_{r=1}^{20} (a_r - \bar{a})^2}. \quad (2.9)$$

Para análise qualitativa, seleciona-se a realização cuja acurácia da GMM com J ótimo é mais próxima da mediana das 20 realizações, gerando matriz de confusão e visualização das superfícies de decisão. Nos *datasets* com mais de duas dimensões, a visualização é realizada por projeção nos dois primeiros componentes principais (PCA).

3 RESULTADOS

Este trabalho avaliou o classificador Bayesiano com Misturas de Gaussianas (GMM-Bayes, $J = 3$ componentes por classe) em cinco conjuntos de dados, comparando-o com LDA, QDA, KNN ($k = 5$) e DMC ao longo de 20 realizações independentes com divisão estratificada 80%/20%. A Tabela 2 consolida os resultados obtidos.

Tabela 2 – Resumo geral — acurácia média (%) dos classificadores por dataset.

Dataset	GMM-Bayes	LDA	QDA	KNN	DMC
Artificial I	100,00	97,69	98,46	100,00	88,85
Breast Cancer	94,12	96,23	95,09	96,49	93,46
Dermatology	89,44	96,94	30,56	96,32	96,25
Íris	95,83	98,33	97,83	95,83	86,83
Coluna Vertebral	80,00	77,98	83,23	77,34	73,47

3.1 Análise por dataset

3.1.1 Artificial I.

O GMM-Bayes obteve acurácia média perfeita (100,00%), empatando com o KNN e superando QDA (98,46%) e LDA (97,69%).

Tabela 3 – Resultados detalhados — Artificial I.

Classificador	Média (%)	DP (%)	Mín (%)	Máx (%)
GMM-Bayes	100,00	0,00	100,00	100,00
LDA	97,69	2,55	92,31	100,00
QDA	98,46	1,88	96,15	100,00
KNN	100,00	0,00	100,00	100,00
DMC	88,85	5,82	73,08	100,00

Esse resultado é esperado: o dataset foi gerado sinteticamente com três clusters bem separados por classe, estrutura multimodal que os modelos de mistura capturam naturalmente. A acurácia perfeita e desvio padrão nulo indicam que os três componentes do GMM representam com exatidão a geometria dos dados, sem necessidade de fronteiras mais complexas como as do KNN.

3.1.2 Breast Cancer (WDBC).

No *Wisconsin Diagnostic Breast Cancer*, o GMM-Bayes obteve acurácia média de A




Figura 1 – Superfície de decisão do discriminante quadrático — Dataset Artificial I




Figura 2 – Matrizes de confusão dos três classificadores — Dataset Artificial I

Tabela 4 – Resultados detalhados — Breast Cancer (WDBC).

Classificador	Média (%)	DP (%)	Mín (%)	Máx (%)
GMM-Bayes	94,43	2,22	89,47	99,12
LDA	96,23	1,57	92,11	98,25
QDA	95,09	1,58	92,98	99,12
KNN	96,49	1,59	92,98	99,12
DMC	93,46	1,56	90,35	96,49

maior variabilidade do GMM-Bayes com uma faixa de quase 7 pontos percentuais entre a pior e a melhor realização reflete a dificuldade de estimar $J = 3$ componentes em $d = 30$ dimensões; na melhor realização (13ª), o modelo chegou a 97,37%, mas em outras rodadas caiu para $\approx 90\%$. Em alta dimensionalidade com apenas duas classes, modelos mais parcimoniosos como o LDA e o KNN mostraram-se mais estáveis.

3.1.3 Dermatology.

O GMM-Bayes atingiu 89,44% de acurácia média de




Figura 3 – Matrizes de confusão dos três classificadores — Dataset Cancer

Tabela 5 – Resultados detalhados — Dermatology.

Classificador	Média (%)	DP (%)	Mín (%)	Máx (%)
GMM-Bayes	89,65	5,26	80,56	98,61
LDA	96,94	1,68	93,06	98,61
QDA	30,56	0,00	30,56	30,56
KNN	96,32	1,66	91,67	98,61
DMC	96,25	2,16	91,67	100,00




Figura 4 – Matrizes de confusão dos três classificadores — Dataset Dermatologia

equivalente à predição da classe majoritária, evidenciando severo overfitting em $d = 34$ atributos. O GMM-Bayes, apesar de mais expressivo, apresentou alta variabilidade (amplitude de ≈ 18 pontos percentuais), alcançando 97,22% na melhor realização (7^a), mas performando abaixo dos modelos lineares e de distância na média geral.

3.1.4 Íris.

O GMM-Bayes obteve

Tabela 6 – Resultados detalhados — Íris.

Classificador	Média (%)	DP (%)	Mín (%)	Máx (%)
GMM-Bayes	95,33	4,14	83,33	100,00
LDA	98,33	1,97	93,33	100,00
QDA	97,83	2,42	93,33	100,00
KNN	95,83	2,07	93,33	100,00
DMC	86,83	4,88	76,67	96,67




Figura 5 – Superfície de decisão do discriminante quadrático — Dataset iris




Figura 6 – Matrizes de confusão dos três classificadores — Dataset iris

Na 3ª realização, o GMM-Bayes chegou à acurácia máxima de 100%, mas sua média foi penalizada por realizações com $\approx 86,67\%$, sugerindo que três componentes por classe introdu-

ziram complexidade desnecessária para um dataset aproximadamente unimodal e linearmente separável.

3.1.5 Coluna Vertebral

No dataset *Vertebral Column*, o GMM-Bayes alcançou 80,00%

Tabela 7 – Resultados detalhados — Coluna Vertebral.

Classificador	Média (%)	DP (%)	Mín (%)	Máx (%)
GMM-Bayes	80,73	3,40	72,58	87,10
LDA	77,98	4,48	66,13	87,10
QDA	83,23	3,93	74,19	88,71
KNN	77,34	3,36	69,35	83,87
DMC	73,47	5,21	62,90	82,26




Figura 7 – Superfície de decisão do discriminante quadrático — Dataset Vertebral




Figura 8 – Matrizes de confusão dos três classificadores — Dataset Vertebral

Com $d = 6$ atributos e três classes, o número de parâmetros do GMM é mais controlável do que nos datasets de alta dimensionalidade, permitindo que o modelo capture não-linearidades moderadas. Ainda assim, o QDA que estima uma única covariância completa por classe apresentou melhor média, indicando que a multimodalidade implícita em $J = 3$ não se traduziu em vantagem consistente neste conjunto.

4 CONCLUSÕES

Com base nos experimentos realizados, as seguintes conclusões podem ser extraídas:

1. **GMM-Bayes é mais eficaz quando os dados são genuinamente multimodais.** No Artificial I, onde cada classe foi gerada com múltiplos focos gaussianos, o modelo atingiu desempenho perfeito. A capacidade de representar distribuições multimodais é a principal vantagem dos GMMs sobre os classificadores de componente único (BISHOP, 2006; THEODORIDIS; KOUTROUMBAS, 2009).
2. **Alta dimensionalidade penaliza o GMM-Bayes.** Nos datasets Breast Cancer (30 atributos) e Dermatology (34 atributos), o GMM-Bayes ficou abaixo dos modelos mais simples. A estimação de $J \cdot d(d+1)/2$ parâmetros de covariância por componente exige um número de amostras por classe muito maior do que o disponível, tornando o modelo suscetível a overfitting (DUDA; HART; STORK, 2001).
3. **LDA mantém robustez em cenários de alta dimensão e separação linear.** Para Íris, Breast Cancer e Dermatology, o LDA apresentou os melhores ou segundo melhores resultados entre os classificadores Bayesianos. Ao impor uma covariância pooled comum, reduz drasticamente o número de parâmetros e generaliza melhor com amostras limitadas (DUDA; HART; STORK, 2001; BISHOP, 2006).
4. **O colapso do QDA no Dermatology é um alerta sobre overfitting.** A acurácia de 30,56% do QDA padrão — equivalente à predição da classe majoritária — demonstra que, sem regularização, estimar uma matriz de covariância completa por classe em dimensão $d = 34$ com poucas amostras é numericamente instável. Essa instabilidade justifica o uso de regularização de Tikhonov ou interpolação com a covariância pooled (BISHOP, 2006).
5. **A escolha do número de componentes J é crítica.** Usar $J = 3$ foi adequado para o Artificial I mas potencialmente excessivo para datasets com classes unimodais (Íris) ou de alta dimensão (Dermatology, Breast Cancer). Uma seleção de J por validação cruzada, como proposto na metodologia, é necessária para equilibrar expressividade e generalização (THEODORIDIS; KOUTROUMBAS, 2009).
6. **O DMC apresentou o pior desempenho consistente.** Em todos os datasets, o DMC ficou na última posição ou próximo dela, confirmando sua limitação a classes com geometria

esférica e bem separadas. A hipótese $\Sigma_i = \sigma^2 \mathbf{I}$ é excessivamente restritiva para dados reais (DUDA; HART; STORK, 2001).

Em síntese, o GMM-Bayes representa um passo natural além dos classificadores Bayesianos gaussianos clássicos, oferecendo maior flexibilidade para representar densidades multimodais. Contudo, essa flexibilidade tem custo: demanda mais dados por classe e um procedimento cuidadoso de seleção de hiperparâmetros. Em cenários de baixa dimensão com dados multimodais, é competitivo ou superior a QDA e LDA; em alta dimensão, regularização e modelos mais parcimoniosos tendem a generalizar melhor.

REFERÊNCIAS

BISHOP, C. M. **Pattern Recognition and Machine Learning**. [S.l.]: Springer, 2006.

DUDA, R. O.; HART, P. E.; STORK, D. G. **Pattern Classification**. 2. ed. [S.l.]: Wiley-Interscience, 2001.

THEODORIDIS, S.; KOUTROUMBAS, K. **Pattern Recognition**. 4. ed. [S.l.]: Academic Press, 2009.